



Факультет компьютерных наук

Мультиаддитивные нейронные
сети

Москва 2025

Энкодеры



Что такое энкодеры

Энкодер – модель или компонент модели, которая преобразует входные данные в векторное представление.



Какие бывают энкодеры

Скрытый слой обученной модели. Например, последний слой ResNet

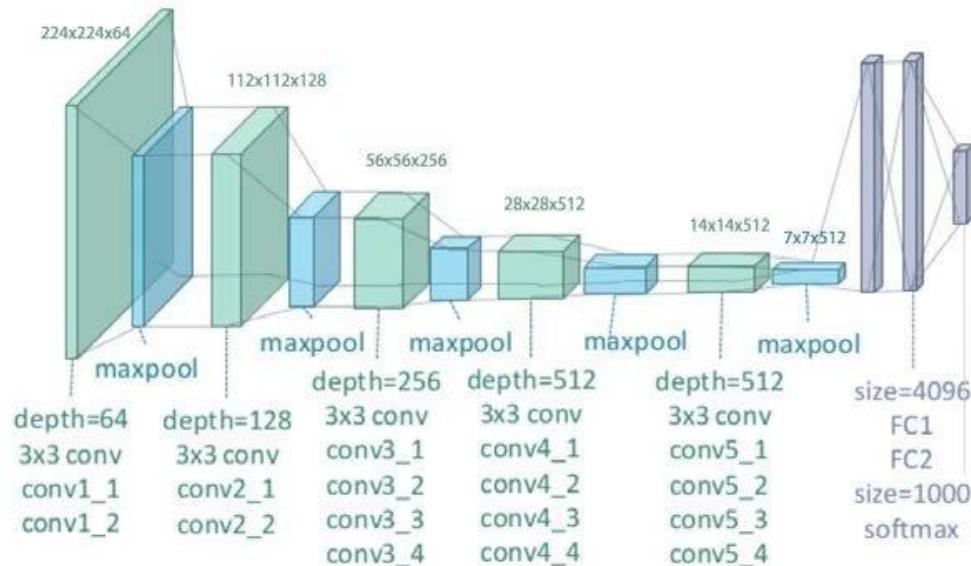
Обучение специальной модели энкодера. Например, BERT

Обучение автокодировщика, например VAE

Обученный энкодер seq2seq модели. Например, Whisper или FridaT5

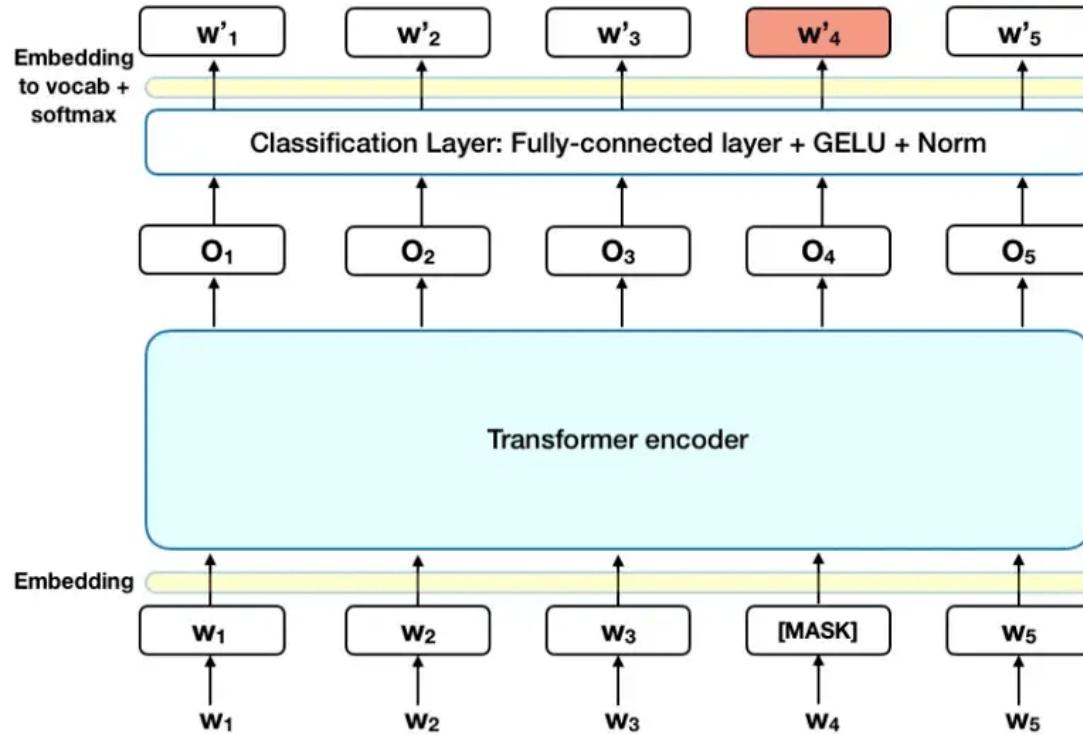


скрытый слой



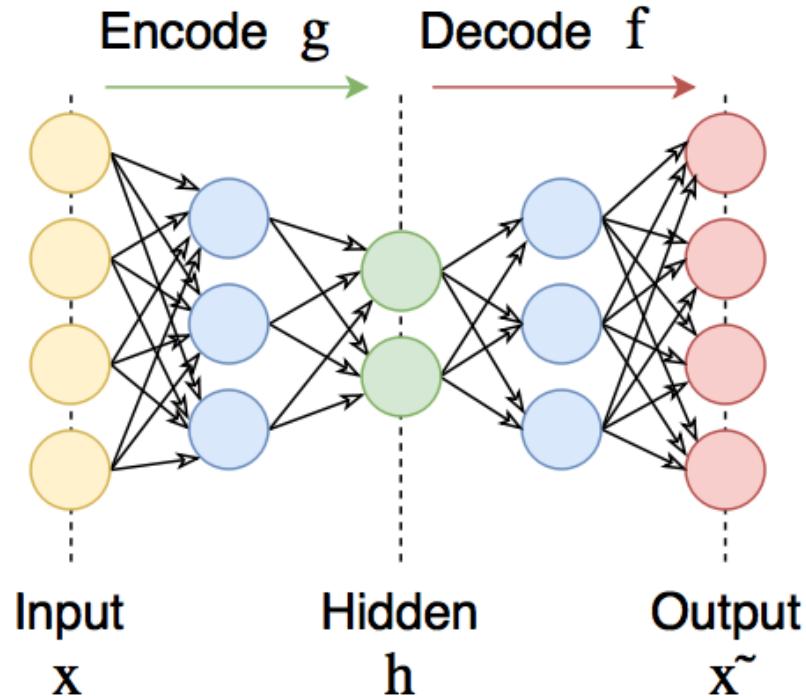


BERT



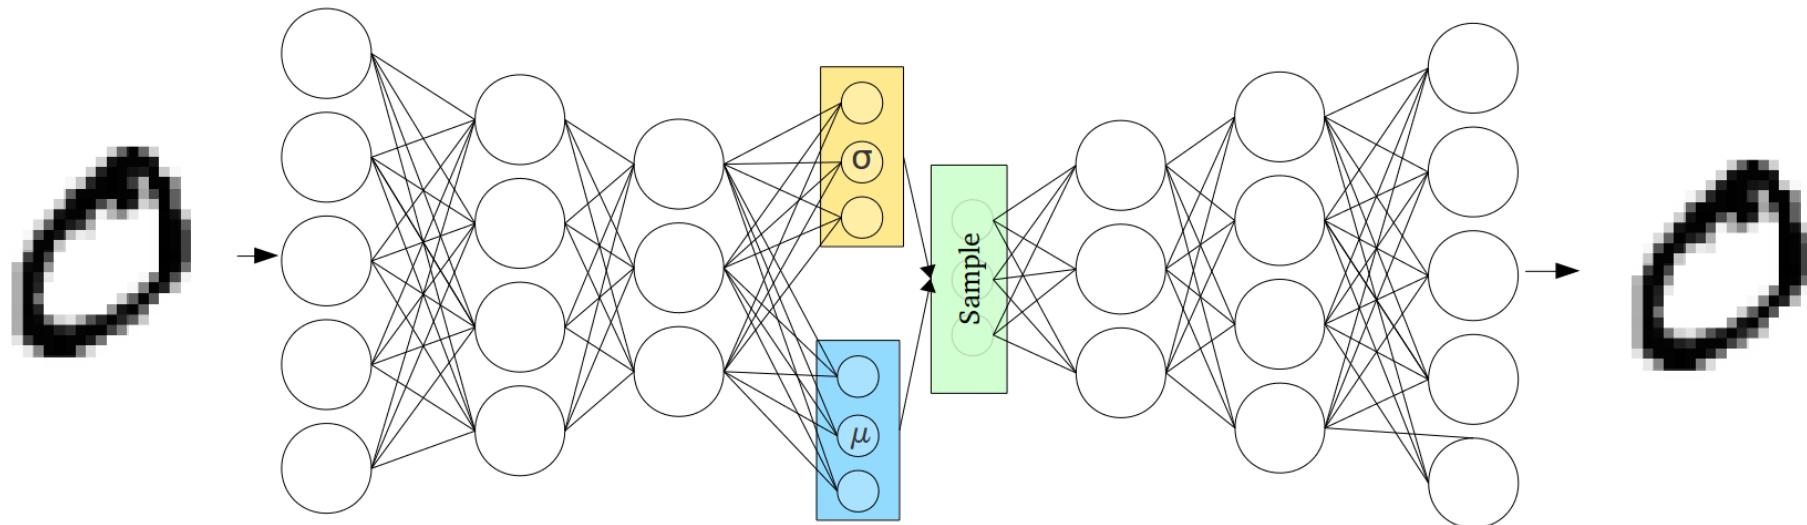


Автокодировщик





Вариационный автокодировщик





Энкодер seq2seq модели

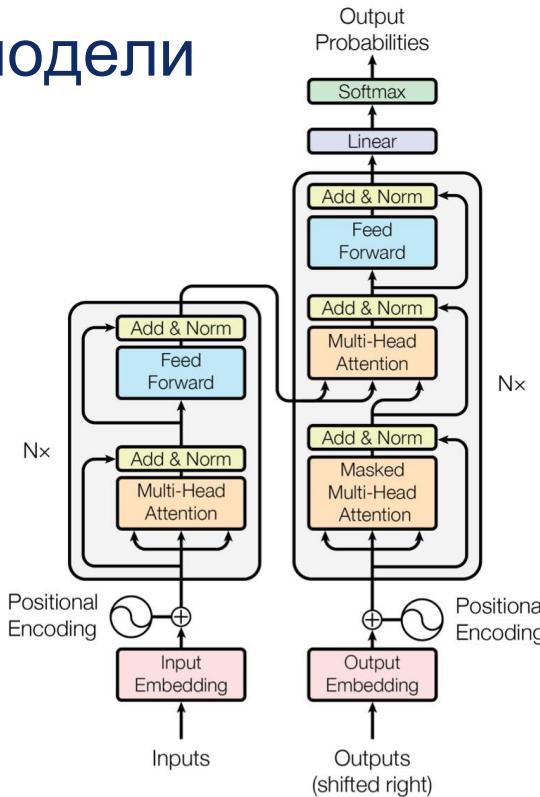


Figure 1: The Transformer - model architecture.



Энкодеры изображений

image to vector: ResNet, AE, VaE

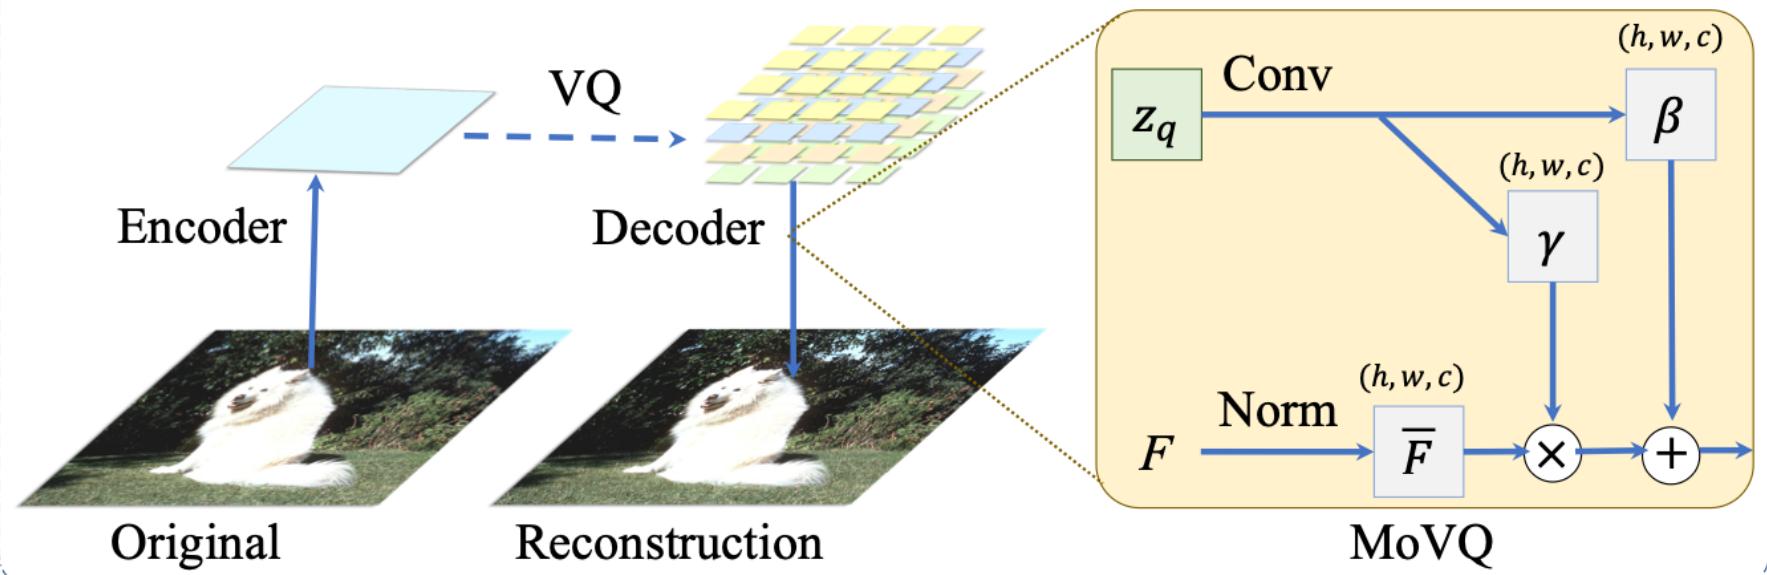
image to latent: VQGAN

Image to sequence: ViT



VQGAN

Stage 1: Modulated VQ Encoder and Decoder Training





VQGAN

отображение входного изображения в скрытое представление
квантизация скрытого представления
реконструкция изображения из многомерного массива токенов



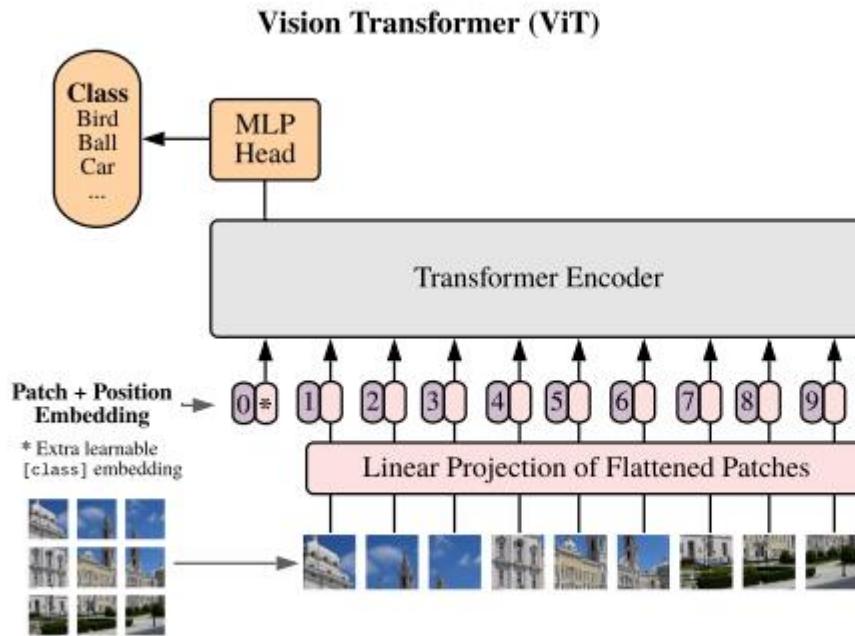
VQGAN. задачи

генерация изображений

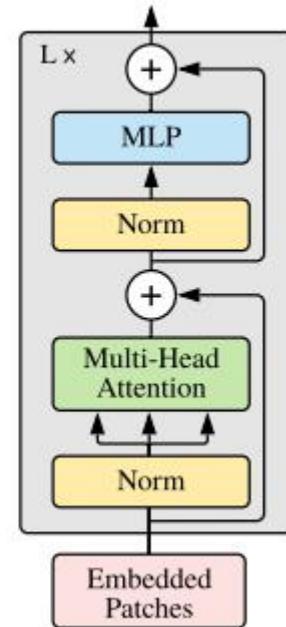
объединение модальностей для генерации изображений



Vision transformer



Transformer Encoder





Vision transformer

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4 / 88.5*
ImageNet ReaL	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k



Vision transformer

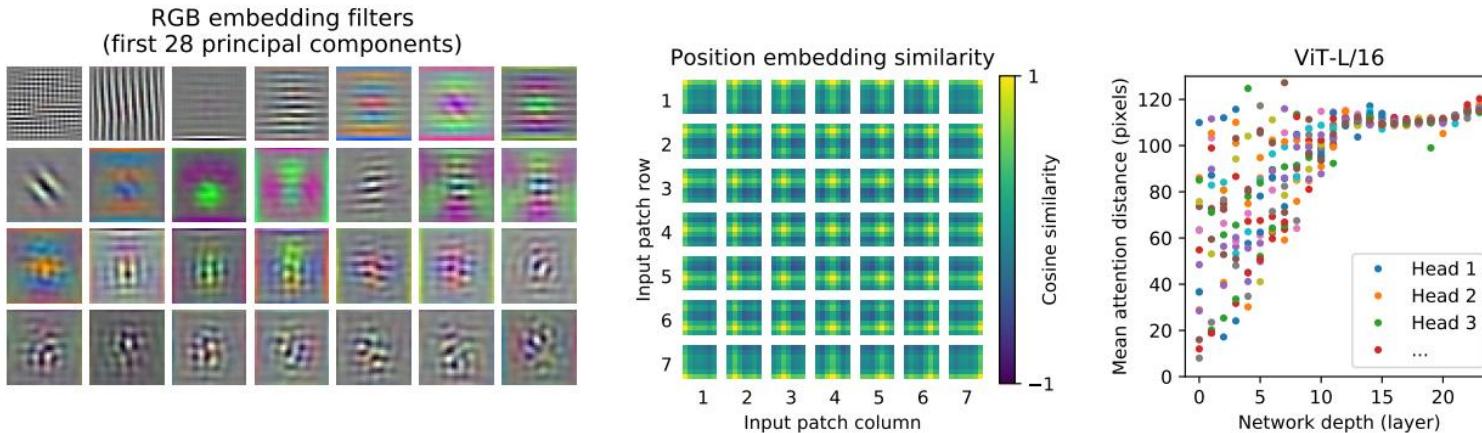


Figure 7: **Left:** Filters of the initial linear embedding of RGB values of ViT-L/32. **Center:** Similarity of position embeddings of ViT-L/32. Tiles show the cosine similarity between the position embedding of the patch with the indicated row and column and the position embeddings of all other patches. **Right:** Size of attended area by head and network depth. Each dot shows the mean attention distance across images for one of 16 heads at one layer. See Appendix D.7 for details.



Vision transformer. Задачи

кодирование изображения в последовательность для LLM
классические задачи с изображениями – классификация, детекция
изображений



Аудио энкодеры

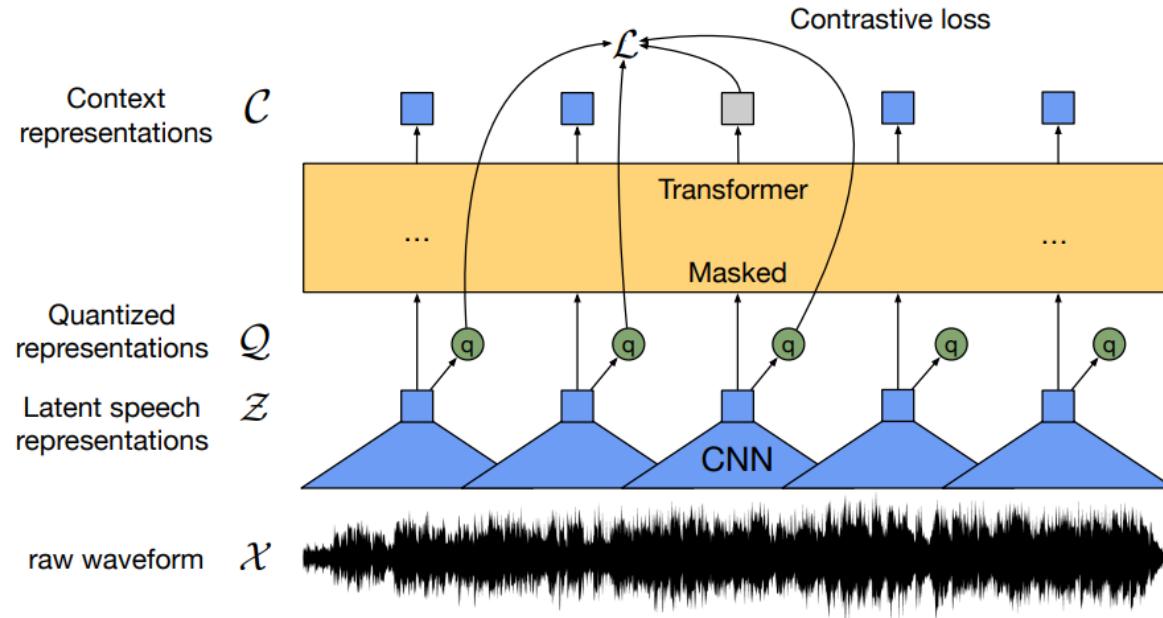
энкодеры – спектrogramма, wav2vec, HuBERT

токенизаторы – RVQ, Encodec, Mimi, Xcodec

большие модели - whisper



Wav2Vec2



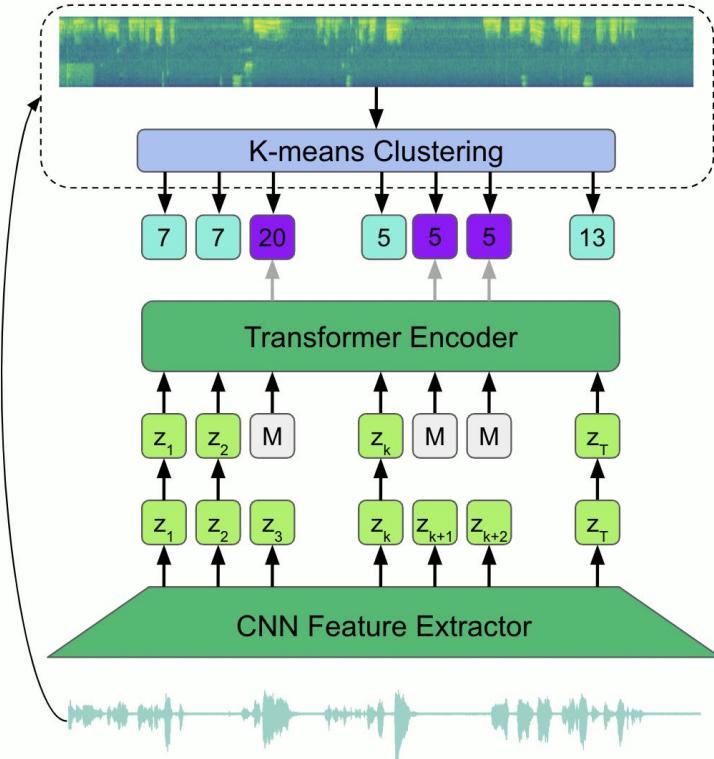


Wav2Vec2

кодирует общую информацию об аудио
подходит для универсальных задач (captioning, classification, etc)



HuBERT





HuBERT

кодирует псевдофонетическую информацию
подходит для речевых задач (ASR, translation, etc)



Whisper

Multitask training data (680k hours)

English transcription

- Ask not what your country can do for ...
- Ask not what your country can do for ...

Any-to-English speech translation

- El rápido zorro marrón salta sobre ...
- The quick brown fox jumps over ...

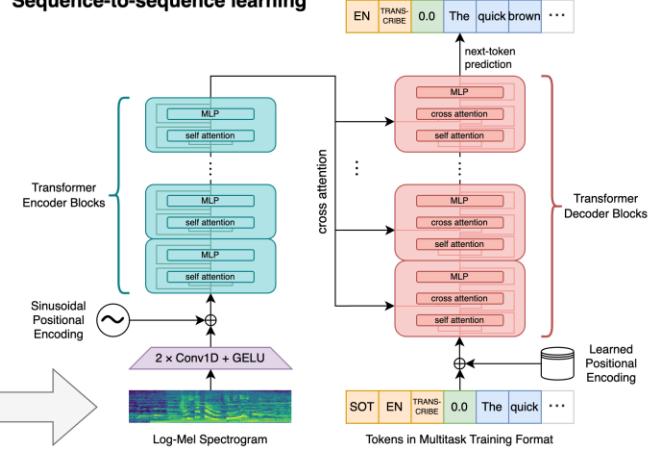
Non-English transcription

- 언덕 위에 올라 내려다보면 너무나 넓고 넓은 ...
- 언덕 위에 올라 내려다보면 너무나 넓고 넓은 ...

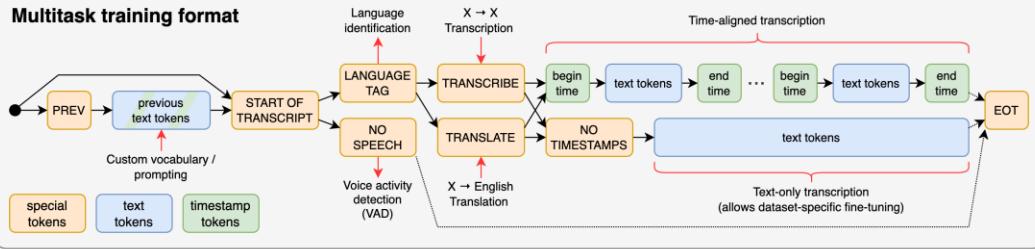
No speech

- (background music playing)
- ∅

Sequence-to-sequence learning



Multitask training format





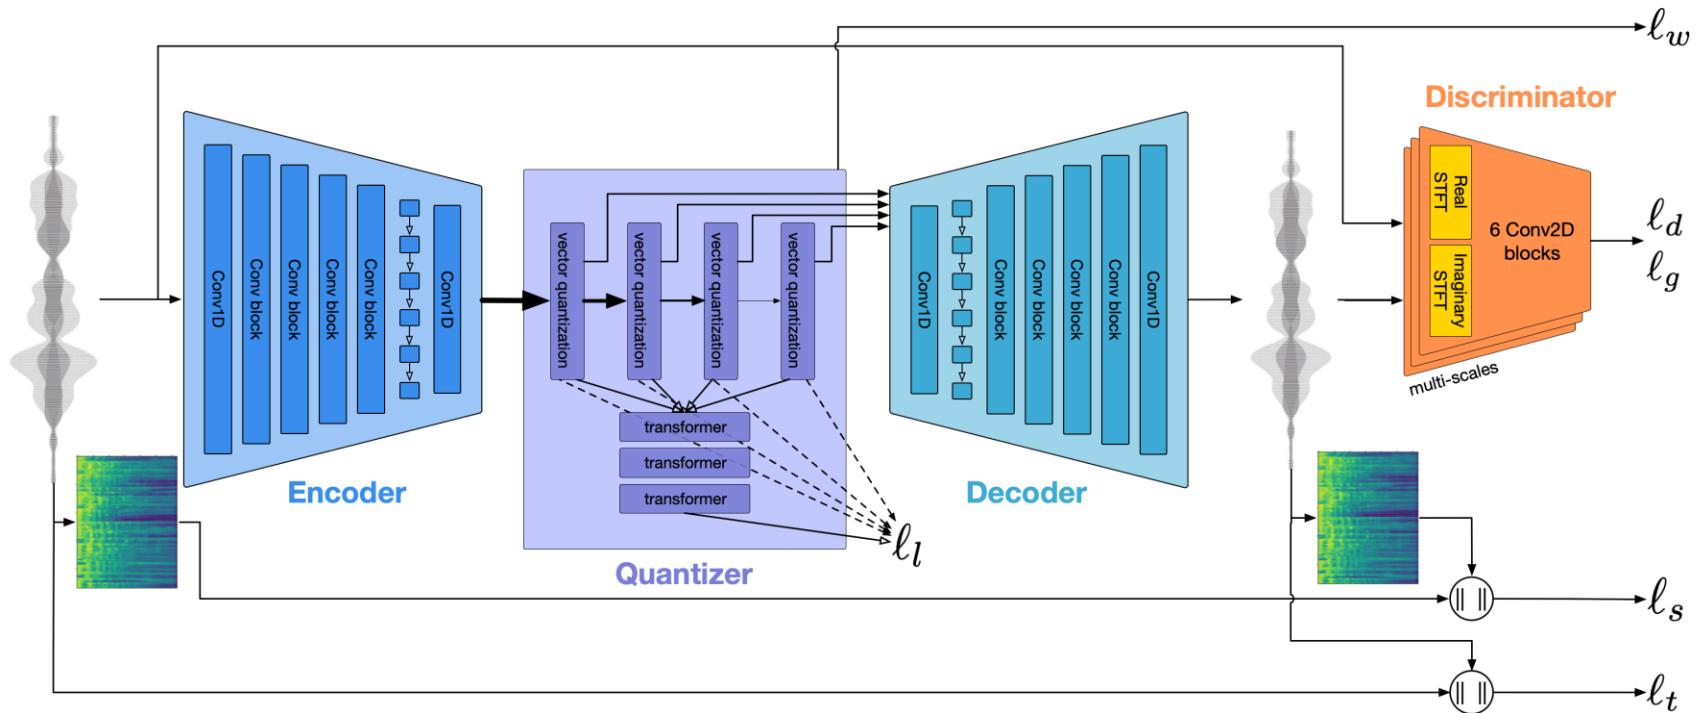
Whisper

понимание языка

мультиязычные задачи



Encodec





Encodec

сжатие аудио
генерация аудио



Видео

кодирование изображения и звука отдельно и объединение
(SALMONN, VideoLLaVa etc)

Специальные энкодеры (Cosmoss)



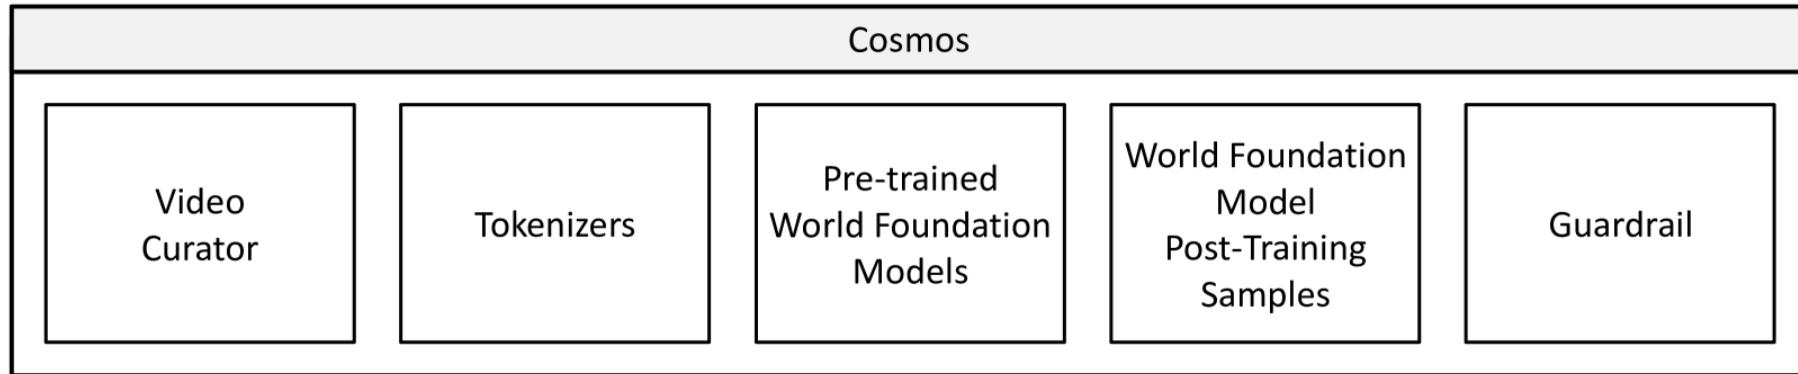
Видео

кодирование изображения и звука отдельно и объединение
(SALMONN, VideoLLaVa etc)

Специальные энкодеры (Cosmoss)



Видео. Cosmos





Видео. Cosmos

